

1. 简单介绍 GCLink

GCLink 是一个用于 **基因调控网络 (GRN) 推断** 的图对比链接预测框架。它把 TF 和 target gene 看成图中的节点，把已知调控关系看成边，把 GRN 推断问题转化为 **link prediction** 问题。论文的核心思路是：先用 **两层 GAT** 从基因表达矩阵和已知调控图中学习节点表示，再通过 **图增强** 构造两个视图（原图保留 + 随机删边图），利用 **跨视图对比学习** 提升在稀疏网络、少样本场景下的表示学习能力，最后通过 **MLP + dot product** 预测 TF-gene 之间是否存在调控关系。

更具体地说，GCLink 的原始方法包含四个关键部分：

- 第一，它把 GRN inference 明确建模成链接预测，而不是传统的纯成对分类。这样模型不仅看两个基因自身，还能通过图结构把邻居信息引入进来。
- 第二，它的编码器是 **两层多头 GAT**。第一层用多头注意力聚合邻居信息，第二层再进一步传播和融合表示，从而获得更稳定的 gene representation。
- 第三，它通过 **Identity + EdgeRemoving** 做图增强，构造 preserved graph 和 perturbed graph，并使用 **inter-view contrastive loss**，让同一基因在两个视图中的表示更接近、不同基因更可分。原论文中这个损失本质上是带正负样本的对比学习，并且总损失是 $L = L_{preser} + L_{pertur} + \beta L_{con}$ ，其中 $\beta=0.5$ 。
- 第四，它的链接预测模块比较直接：先把 GAT 输出送入 MLP 得到低维 embedding，再对 TF embedding 和 target embedding 做 **dot product**，最后经过 sigmoid 得到边概率。

从论文实验看，GCLink 的主要优势是：在多数基准数据集上优于多种基线；在 few-shot 场景下通过 pretrain + fine-tune 仍有较好的泛化能力；在噪声图和稀疏图条件下也比 GENELink 更稳。论文还特别指出，随机删边概率 **0.2** 往往效果最好，对比学习还能提升 AUPRC 并降低波动。

2. 相对原版的改进点和优势

我保留了 GCLink 的整体框架（GAT 编码器 + 双视图图增强 + 监督链接预测），但把原版的 dot-product decoder 改成了 EdgeMLP，把原版的 InfoNCE 风格图对比学习改成了 SimSiam。

所以我的方法不再是“原版 GCLink”，而更准确地说是：**基于 GCLink 的改进模型**，或者叫 **GCLink + EdgeMLP + SimSiam**。这里我起名为 SELink（鬼知道为啥我要叫这个名字）

2.1 第一处改进：把 decoder 从 dot 改成 EdgeMLP

原版 GCLink 的链接预测模块是：先得到 TF embedding 和 target embedding，然后做 **点积打分**。原版代码里 `Type='dot'`，训练时对两个增强视图分别做 BCE，再加上对比损失。

针对原版 GCLink 中解码器表达能力有限、对有序调控关系建模不足的问题，我们用 EdgeMLP 替代了 dot-product decoder，通过显式构造边级交互特征提升链接判别能力。

具体来说，我在 `scGNnv2.py` 中加入了新的 decoder 选项，其中最关键的是 `edge_mlp`。我的 `edge_mlp` 不再只依赖 $u \cdot v$ ，而是显式构造边级特征：

- `u`
- `v`
- `u*v`

- $|u-v|$
- $u-v$
- $u+v$

然后把这些组合特征送入多层 MLP 输出一个 logit。

意思是，我的链接预测思路从原版的：“节点 embedding 是否相容”变成了：“把一对节点看成一条候选边，直接学习边级判别函数”。

这一改动相对原版的优势主要体现在三点：

- 第一，**表达能力更强**。
dot product 本质上是很受限的双线性相似度，适合做粗粒度匹配；而 EdgeMLP 可以学习更复杂的非线性关系，能更细致地区分正负调控边。
- 第二，**更适合有向调控关系**。
在 GRN 中，TF→gene 是有方向的。我显式用了 $u-v$ 这一类方向敏感特征，因此比单纯的点积更容易捕捉“谁调控谁”的非对称性。
- 第三，**边级建模更完整**。
我同时保留了节点本身特征 (u, v)、交互特征 ($u*v$)、距离特征 ($|u-v|$)、方向特征 ($u-v$) 和整体组合特征 ($u+v$)，这比原版只靠一个点积标量打分更丰富。

2.2 第二处改进：把原版对比学习换成 SimSiam

原版 GCLink 的对比学习来自论文和原始代码中的 **inter-view contrastive learning**。论文明确写了：对 preserved graph 中的节点表示和 perturbed graph 中对应节点表示构成正样本，与其他节点构成负样本，使用的是典型的对比学习目标。原始代码实现上则对应 `DualBranchContrast(loss=L.InfoNCE(...), mode='L2L', intraview_negs=False)`，也就是 **InfoNCE 风格** 的双分支节点对比。

针对原版 GCLink 中基于负样本的对比学习可能引入噪声监督的问题，我们用 SimSiam 替代原有 InfoNCE 对比目标，在不依赖负样本的情况下实现跨视图表示对齐，并通过 warmup 策略提升训练稳定性。

具体而言，我在 `GCLink_main_SimSiam.py` 中做了一个替换：我没有再使用 `DualBranchContrast + InfoNCE`，而是自己实现了：

- `SimSiamHead`
- `projector`
- `predictor`
- `stop-gradient`
- 对称的 cosine loss

也就是把原版“有负样本的对比学习”换成了 **SimSiam 式无负样本表示对齐**。

我的 SimSiam 训练逻辑是：

- 训练阶段仍然保留两种图增强；
- 对两个视图得到的节点嵌入 `embed1`、`embed2` 做 projector + predictor；
- 使用 stop-gradient 后的另一分支投影作为对齐目标；
- 最终总损失为 **BCE + λ ·SimSiamLoss**。

相对原版，这个改动的优势主要有四点：

- **第一，不依赖显式负样本。**
原版 InfoNCE 需要把其他节点当作负样本，而在 GRN 场景中，很多“未标注边/未标注节点关系”未必真的是负样本。SimSiam 避免了这种负样本构造带来的潜在偏差。这个优势虽然是方法层面的推断，但和我换用 SimSiam 的动机是高度一致的。对应代码上，我已经完全取消了对比分支实现。
- **第二，训练机制更简洁。**
我不再依赖对比库中的 DualBranchContrast，而是把 projector、predictor 和 loss 写进自己的训练流程中，逻辑更可控。
- **第三，更容易和监督目标协同。**
我用了 warmup 机制，让对比项权重 `lam` 随 epoch 增长，而不是一开始就强行压上去。这相比原版固定 $0.5 \times \text{contrastive loss}$ ，更适合防止训练早期表示被自监督项干扰。
- **第四，工程上更稳定更完整。**
我的代码里显式加入了 `BCEWithLogitsLoss`、梯度裁剪、resume checkpoint、对 macOS/MPS 的兼容处理，以及只在训练阶段做增强、评估阶段直接在原图上跑一次，这些都比原始脚本更完整。

2.3 All in All

总的来说，我的模型相对原版 GCLink 的主要优势可以总结为：

- **第一，边预测更强。**
原版是“embedding 相似度打分”，我变成了“边级特征判别”，对复杂调控关系建模更充分。
- **第二，自监督更稳。**
原版依赖 InfoNCE 负样本机制，我改成 SimSiam 后更强调正对齐和 bootstrap consistency，理论上更适合标签稀疏、负样本不纯的场景。我的代码中还加入了 warmup 权重来进一步稳定训练。
- **第三，仍然保留了 GCLink 的核心优点。**
我没有推翻 GCLink，而是保留了它最重要的框架基础：GAT 编码器、双视图图增强、少样本场景下的表示学习思路。也就是说，我的工作是在 GCLink 框架上增强判别器和替换自监督目标，不是另起炉灶。

3. 对照表

对比维度	原版 GCLink	改进版
任务定义	将 GRN 推断建模为 link prediction	保持不变，仍然是 link prediction 框架
图表示学习 backbone	两层多头 GAT 编码器	保持两层 GAT 主干不变，便于控制变量
图增强方式	Identity + EdgeRemoving，构造 preserved/perturbed 两个视图	保持同样的双视图增强方式，仍使用 <code>Identity()</code> 和 <code>EdgeRemoving(pe=0.2)</code>
对比/自监督目标	Inter-view contrastive learning，InfoNCE 风格，含正负样本	用 SimSiam 替代原始对比学习，不依赖负样本，采用 projector + predictor + stop-grad
decoder	MLP 得到低维 embedding 后，用 dot product 计算边分数	用 EdgeMLP 替代 dot decoder，显式建模边级特征

对比维度	原版 GCLink	改进版
边方向信息	点积本身对方向建模较弱	u-v 等特征显式保留方向信息，更适合有向 GRN
损失函数	<code>BCE(view1) + BCE(view2) + 0.5 * contrastive loss</code>	<code>BCEWithLogits(view1/view2) + 1am * SimSiamLoss</code> ，并加入 warmup 逐步增大自监督权重
预训练策略	先做带增强的监督预训练，再正式训练	仍保留 pretrain 思路，但训练细节更完整，使用 BCEWithLogitsLoss、梯度裁剪、resume 机制
评估阶段逻辑	原始脚本中训练/验证都沿用双视图框架	评估阶段直接在原图上跑一次，不再做增强，预测逻辑更清晰
方法定位	原始 GCLink	基于 GCLink 的改进版： GCLink + EdgeMLP + SimSiam